

Construção do modelo de classificação de risco

Percurso completo de treinamento, ajuste e validação dos algoritmos de aprendizado de máquina aplicados à identificação de comportamento compulsivo em plataformas de apostas online, desde a integração da base de dados até a definição do modelo final.

BASE DE DADOS

bwin – Gray et al. (2012)

USUÁRIOS ANALISADOS


4.113

14

ALGORITMOS COMPARADOS

4

TRILHA DO DESENVOLVIMENTO



Objetivo

O propósito desta etapa do trabalho foi desenvolver e validar um modelo capaz de classificar usuários de plataformas de apostas online em três níveis de risco de comportamento compulsivo — baixo, médio e alto — a partir exclusivamente de dados comportamentais registrados pela própria plataforma.

A escolha do algoritmo não foi definida previamente. Quatro algoritmos de classificação foram comparados sob as mesmas condições de treinamento e avaliação, e o modelo final foi selecionado com base em desempenho medido, não em preferência teórica. As métricas adotadas para essa decisão foram a área sob a curva ROC, o F1-score e o recall, com atenção particular ao recall da classe de alto risco, dado que deixar de identificar um apostador em situação grave é o erro de maior custo no contexto de jogo responsável.

Como ler este documento

As etapas estão apresentadas na ordem em que foram executadas. Cada uma registra o que se pretendia investigar, quais dados e técnicas foram utilizados, qual resultado se obteve e quais arquivos foram gerados. Etapas que produziram resultados não incorporados ao modelo final estão marcadas como tal — elas permanecem no registro porque a decisão de descartá-las é parte do método, e não uma lacuna.

Os nomes de arquivos aparecem em fonte monoespaçada e correspondem exatamente aos gerados durante a execução, permitindo rastrear qualquer número apresentado até sua origem.

Base de dados

Os dados utilizados provêm do estudo *Behavioral Characteristics of Internet Gamblers Who Trigger Corporate Responsible Gambling Interventions*, conduzido por Gray, LaPlante e Shaffer (2012) na Division on Addiction do Cambridge Health Alliance, hospital de ensino da Harvard Medical School. A base é disponibilizada publicamente pelo Transparency Project e reúne registros reais de apostadores da operadora bwin.

A base é composta por três arquivos complementares, conectados pelo identificador de usuário. O primeiro contém informações cadastrais e demográficas dos 4.134 apostadores da coorte. O segundo reúne 981.782 registros de atividade diária de apostas, detalhando por dia e por tipo de produto o valor apostado, o valor perdido e o número de apostas realizadas. O terceiro documenta os 2.068 usuários que acionaram o programa de jogo responsável da operadora, com o tipo de evento registrado e a intervenção aplicada.

Esse terceiro arquivo cumpre o papel de referência de classificação do modelo: a marcação feita pelo programa de jogo responsável da operadora indica quais

usuários foram efetivamente identificados como problemáticos, funcionando como o julgamento que o modelo aprende a reproduzir a partir dos padrões de comportamento.

Percurso experimental

Quatorze etapas executadas em sequência, da integração dos arquivos brutos à interpretação do modelo final.

01

Integração dos arquivos da base

DADOS

OBJETIVO

Unificar os três arquivos distribuídos separadamente pelo Transparency Project em uma única estrutura de análise, de modo que cada registro de atividade estivesse acompanhado das características do usuário e de sua eventual marcação pelo programa de jogo responsável.

PROCEDIMENTO

Os arquivos foram carregados com a biblioteca Pandas e unidos pelo campo identificador de usuário. O arquivo de agregados diários foi adotado como base da junção, por representar o nível mais granular de informação — um registro por usuário, por dia e por tipo de produto. Os demais foram incorporados por junção à esquerda, preservando todos os registros de atividade e atribuindo valor ausente aos usuários sem histórico no programa de jogo responsável.

RESULTADO

Estrutura unificada com 981.782 registros e 18 colunas, cobrindo a coorte completa de 4.134 usuários.

```
combined_bwin_dataset.csv
```

02

Agregação por usuário e construção das variáveis comportamentais

DADOS

OBJETIVO

Converter os registros diários em um perfil comportamental consolidado por usuário. Um modelo de classificação exige uma linha por indivíduo, com as

variáveis que descrevem seu padrão de jogo ao longo de todo o período observado.

VARIÁVEIS CONSTRUÍDAS

Sete variáveis foram derivadas dos registros diários, escolhidas por corresponderem aos indicadores apontados como mais relevantes na literatura revisada no trabalho.

total_dias_ativos

total_apostado

media_diaria_apostada

desvio_padrao_apostado

total_perdas

numero_total_apostas

variedade_produtos

DEFINIÇÃO INICIAL DA VARIÁVEL-ALVO

A classe de alto risco foi atribuída aos usuários marcados pelo programa de jogo responsável da operadora. Os demais foram divididos entre baixo e médio risco pela mediana do valor total apostado, estabelecida em R\$ 238,85.

RESULTADO

Base agregada com 4.113 usuários e 21 colunas. A diferença em relação aos 4.134 da coorte original corresponde aos usuários sem qualquer registro de atividade de apostas.

bwin_dataset_agregado_classificado.csv

03

Redefinição da variável-alvo por escore composto

DADOS

OBJETIVO

Substituir o critério unidimensional adotado na etapa anterior. Separar baixo de médio risco apenas pelo valor total apostado ignora dimensões igualmente relevantes do comportamento — um usuário pode apostar pouco em termos absolutos, mas fazê-lo com frequência diária e grande variabilidade, padrão que a literatura associa a risco.

PROCEDIMENTO

Foi construído um escore de intensidade combinando quatro variáveis: total de dias ativos, valor total apostado, variedade de produtos e desvio padrão do valor apostado. Cada variável foi convertida em percentil dentro da população sem marcação de jogo responsável, e o escore de cada usuário corresponde à média dos quatro percentis.

A conversão em percentis antes da combinação foi necessária porque as quatro variáveis operam em escalas incompatíveis — dias ativos variam na casa das centenas, valores apostados podem alcançar milhões e a variedade de produtos vai de um a sete. Somar valores brutos faria com que o total apostado dominasse integralmente o escore, reproduzindo o problema que se buscava corrigir. Normalizadas em percentis, as quatro dimensões pesam igualmente.

RESULTADO

Limiar estabelecido na mediana do escore, em 49,74. A distribuição final entre as classes ficou assim:

CLASSE	CRITÉRIO	USUÁRIOS
Baixo risco	Escore $\leq$ 49,74	1.023
Médio risco	Escore $>$ 49,74	1.022
Alto risco	Marcação do programa RG	2.068

bwin_dataset_agregado_classificado.csv

OBSERVAÇÃO METODOLÓGICA

A classe de alto risco decorre de um evento concreto — a marcação pela operadora. As classes de baixo e médio risco decorrem de um corte estatístico em uma distribuição contínua. Essa diferença de natureza explica boa parte do comportamento observado nas etapas seguintes: a fronteira entre baixo e médio é construída, não observada, e por isso mais difícil de aprender.

Treinamento inicial dos quatro algoritmos

OBJETIVO

Estabelecer uma referência de desempenho para os quatro algoritmos definidos no trabalho, executados com configurações padrão e sob condições idênticas, permitindo comparação direta entre eles.

PROCEDIMENTO

Divisão dos dados em 80% para treinamento e 20% para teste, com estratificação pela classe de risco para preservar a proporção entre as três categorias em ambos os conjuntos. A semente aleatória foi fixada em 42 para garantir reprodutibilidade.

O pré-processamento foi encapsulado em um pipeline aplicado igualmente aos quatro algoritmos: imputação de valores ausentes pela mediana nas variáveis numéricas e pela moda nas categóricas, padronização das numéricas e codificação one-hot das categóricas. As variáveis usadas na construção da variável-alvo foram excluídas do conjunto de atributos, evitando que os modelos simplesmente memorizassem a regra de classificação em vez de aprender padrões comportamentais.

RESULTADO — MÉDIAS MACRO

ALGORITMO	ACURÁCIA	AUC	F1	RECALL
XGBoost	0,819	0,923	0,811	0,811
Random Forest	0,823	0,922	0,812	0,811
Logistic Regression	0,727	0,874	0,679	0,684
Decision Tree	0,719	0,784	0,718	0,721

RESULTADO — DESEMPENHO POR CLASSE

ALGORITMO	BAIXO RISCO		MÉDIO RISCO		
	AUC	RECALL	AUC	RECALL	AUC
XGBoost	0,985	0,932	0,892	0,662	0,891
Random Forest	0,983	0,937	0,888	0,642	0,896
Logistic Regression	0,951	0,839	0,799	0,363	0,873
Decision Tree	0,915	0,873	0,705	0,574	0,732

model_comparison_by_class.csv

model_comparison_summary.csv

ANÁLISE

Os dois algoritmos baseados em combinação de árvores superaram claramente os demais, com desempenho estatisticamente equivalente entre si. A árvore de decisão isolada apresentou o comportamento esperado de sobreajuste, com bom resultado na classe de baixo risco e generalização fraca nas demais.

A regressão logística registrou o resultado mais discrepante: recall de 0,363 na classe de médio risco, muito abaixo de seu próprio desempenho nas outras duas. A

explicação para esse contraste só se tornou clara na etapa 14.

05

Visualização comparativa dos resultados iniciais

ANÁLISE

OBJETIVO

Representar graficamente a comparação entre os quatro algoritmos, facilitando a identificação de padrões que as tabelas numéricas tornam menos evidentes — em particular a diferença de dificuldade entre as três classes de risco.

RESULTADO

Quatro gráficos de barras agrupadas, produzidos com Matplotlib e Seaborn: um consolidando as médias macro das quatro métricas e três detalhando AUC, F1-score e recall por classe de risco.

grafico_resumo_macro.png

grafico_auc_por_classe.png

grafico_f1_por_classe.png

grafico_recall_por_classe.png

ANÁLISE

A visualização evidenciou de forma imediata que a classe de médio risco constitui o gargalo do problema para todos os algoritmos testados, sem exceção. Baixo e alto risco alcançam patamares consistentemente superiores, enquanto o médio risco concentra a maior parte do erro do sistema.

06

Ajuste de hiperparâmetros priorizando alto risco

MODELAGEM

OBJETIVO

Otimizar as configurações dos dois algoritmos de melhor desempenho, tomando como critério exclusivo a maximização do recall na classe de alto risco — partindo da premissa de que deixar de identificar um apostador em situação grave é o erro mais custoso do sistema.

PROCEDIMENTO

Busca aleatória sobre 40 combinações de hiperparâmetros, com validação cruzada estratificada de cinco divisões. A função de avaliação foi customizada para medir exclusivamente o recall da classe de alto risco, e não a acurácia geral ou a média entre classes.

CONFIGURAÇÕES ENCONTRADAS

Random Forest — recall de 0,9075 em validação cruzada

`n_estimators` 351

`max_depth` 5

`max_features` log2

`min_samples_leaf` 4

`min_samples_split` 3

XGBoost — recall de 0,8452 em validação cruzada

`n_estimators` 194

`max_depth` 4

`learning_rate` 0,057

`subsample` 0,718

`colsample_bytree` 0,631

`gamma` 0,116

RESULTADO — CLASSE DE ALTO RISCO

MODELO	FASE	AUC	F1	RECALL
Random Forest	Antes	0,896	0,841	0,855
Random Forest	Depois	0,879	0,793	0,899
XGBoost	Antes	0,891	0,833	0,841
XGBoost	Depois	0,905	0,844	0,855

RESULTADO — EFEITO SOBRE A CLASSE DE MÉDIO RISCO

MODELO	FASE	F1	RECALL
Random Forest	Antes	0,701	0,642
Random Forest	Depois	0,390	0,255
XGBoost	Antes	0,701	0,662
XGBoost	Depois	0,723	0,677

tuning_before_after_by_class.csv

grafico_tuning_random_forest.png

grafico_tuning_xgboost.png

CONSEQUÊNCIA NÃO PRETENDIDA

O Random Forest elevou o recall de alto risco de 0,855 para 0,899, mas ao custo de reduzir o recall de médio risco de 0,642 para 0,255. A busca encontrou uma configuração de árvores rasas — profundidade máxima de 5

— que empurra casos ambíguos da classe intermediária para a classe superior. Reduzem-se os falsos negativos de alto risco, mas às custas de praticamente eliminar a capacidade de reconhecer a classe do meio. O XGBoost, em contraste, obteve ganho em todas as frentes simultaneamente.

Interpretabilidade e detecção de viés geográfico

ANÁLISE

OBJETIVO

Identificar quais variáveis efetivamente sustentam as decisões do modelo, verificando se o desempenho observado decorre de padrões comportamentais — como o trabalho propõe — ou de outros fatores presentes nos dados.

PROCEDIMENTO

Aplicação da técnica SHAP sobre o XGBoost ajustado, quantificando a contribuição de cada variável para cada predição individual. Foram gerados o ranking geral de importância e o gráfico de distribuição de impacto para a classe de alto risco.

RESULTADO

No ranking geral, o valor total apostado apareceu como variável mais influente. Na predição específica de alto risco, porém, o padrão foi outro: as variáveis de país e idioma dominaram a decisão, superando todas as variáveis comportamentais. Pertencer à Itália empurrava fortemente a predição para alto risco; pertencer à Turquia empurrava na direção oposta, com padrões binários nítidos.

shap_importancia_geral.png

shap_beeswarm_alto_risco.png

shap_ranking_variaveis.csv

ACHADO CRÍTICO

O modelo estava aprendendo, em parte considerável, onde a operadora fiscaliza com mais rigor — e não quem se comporta como apostador em situação de risco. Países com programas de detecção mais agressivos geram historicamente mais marcações, e o modelo capturou essa regularidade regulatória. Classificar um usuário como alto risco por sua nacionalidade contraria diretamente o objetivo do trabalho, que é identificar risco a partir de comportamento observado.

Remoção das variáveis demográficas

MODELAGEM

OBJETIVO

Quantificar o custo, em desempenho, de eliminar o viés identificado na etapa anterior. Retreinar os modelos apenas com variáveis comportamentais e medir a diferença em relação aos modelos que incluíam país, idioma, gênero e ano de nascimento.

RESULTADO — MÉDIAS MACRO

MODELO	CONJUNTO DE VARIÁVEIS	AUC	F1	RECALL
Random Forest	Com demográficas	0,922	0,812	0,812
Random Forest	Só comportamentais	0,905	0,787	0,787
XGBoost	Com demográficas	0,923	0,811	0,811
XGBoost	Só comportamentais	0,891	0,761	0,761

```
comparison_demographics_vs_behavioral_only.csv
```

```
grafico_demograficas_vs_comportamental_rf.png
```

```
grafico_demograficas_vs_comportamental_xgb.png
```

ANÁLISE E DECISÃO

A perda ficou entre dois e quatro pontos percentuais, concentrada na classe de médio risco. O XGBoost perdeu mais que o Random Forest — queda de 0,034 contra 0,017 em AUC macro — confirmando que se apoiava mais intensamente nas variáveis de país, exatamente como a análise SHAP indicara.

A decisão foi manter apenas variáveis comportamentais em todas as etapas seguintes. A perda é moderada e o ganho é substantivo: o modelo passa a prever risco a partir de como a pessoa joga, não de onde ela é. Além da coerência com o objetivo do trabalho, isso favorece a generalização para outros mercados, incluindo o brasileiro, cujo perfil regulatório não está representado na base.

Engenharia de atributos avançada

DADOS

OBJETIVO

Recuperar parte do desempenho perdido com a remoção das variáveis demográficas por meio da criação de novos atributos comportamentais, capazes de capturar

padrões temporais e proporções que as sete variáveis originais, centradas em volume bruto, não representavam.

VARIÁVEIS CRIADAS

VARIÁVEL	DEFINIÇÃO
taxa_perda_sobre_apostado	Razão entre o total perdido e o total apostado
intensidade_apostas_por_dia_ativo	Número de apostas dividido pelos dias de atividade
tendencia_crescimento_apostado	Inclinação da regressão linear do valor apostado ao longo do tempo
concentracao_apostas_dias_ativos	Coefficiente de Gini da distribuição diária do valor apostado
media_apostas_por_produto	Número de apostas dividido pela variedade de produtos

As duas primeiras e a última são razões calculadas sobre a base já agregada. A tendência de crescimento e o índice de concentração exigiram reprocessar os registros diários usuário a usuário, por dependerem da sequência temporal completa.

RESULTADO — MÉDIAS MACRO

MODELO	ATRIBUTOS	AUC	F1	RECALL
Random Forest	7 originais	0,905	0,787	0,788
Random Forest	12 estendidos	0,907	0,793	0,794
XGBoost	7 originais	0,891	0,761	0,763
XGBoost	12 estendidos	0,902	0,764	0,764

```
bwin_dataset_features_avancadas.csv
```

```
comparison_original_vs_extended_behavioral.csv
```

```
grafico_original_vs_estendido_rf.png
```

grafico_original_vs_estendido_xgb.png

grafico_importancia_novas_variaveis.png

ANÁLISE

Ganho consistente porém modesto, entre 0,2 e 1,1 ponto percentual de AUC. A classe de médio risco foi a mais beneficiada — F1 do Random Forest passou de 0,652 para 0,670 e do XGBoost de 0,611 para 0,622 — coerente com o fato de que os novos atributos descrevem padrões de distribuição e ritmo, e não volume absoluto.

Entre as cinco variáveis criadas, a média de apostas por produto foi a mais relevante, alcançando a quinta posição no ranking de importância do Random Forest, acima inclusive do total de dias ativos. Tendência de crescimento e taxa de perda ficaram nas posições mais baixas.

10

Ajuste de hiperparâmetros priorizando equilíbrio entre classes

MODELO FINAL

OBJETIVO

Reotimizar os hiperparâmetros sobre o conjunto completo de doze variáveis comportamentais, dessa vez adotando como critério o recall médio das três classes em vez do recall isolado da classe de alto risco — evitando o desequilíbrio observado na etapa 06.

PROCEDIMENTO

Busca aleatória com validação cruzada estratificada de cinco divisões, com função de avaliação definida como a média simples do recall entre as três classes. Essa mudança retira do otimizador o incentivo de sacrificar uma classe em favor de outra.

CONFIGURAÇÕES ENCONTRADAS

XGBoost — recall macro de 0,7967 em validação cruzada

n_estimators 279

max_depth 3

learning_rate 0,021

subsample 0,764

colsample_bytree 0,720

min_child_weight 2

gamma 0,114

Random Forest — recall macro de 0,8074 em validação cruzada

n_estimators 529

max_depth 10

max_features sqrt

`min_samples_leaf 2``min_samples_split 11``class_weight balanced`

RESULTADO — MÉDIAS MACRO

MODELO	FASE	AUC	F1	RECALL
XGBoost	Antes	0,902	0,764	0,764
XGBoost	Depois	0,915	0,801	0,803
Random Forest	Antes	0,907	0,793	0,794
Random Forest	Depois	0,913	0,780	0,796

`tuning_behavioral_before_after_by_class.csv``grafico_tuning_behavioral_rf.png``grafico_tuning_behavioral_xgb.png`

ANÁLISE

O XGBoost obteve ganho consistente em todas as métricas, com o recall macro subindo de 0,764 para 0,803. A configuração encontrada combina taxa de aprendizado baixa com maior número de árvores rasas, o que reduz o sobreajuste e melhora a generalização.

O Random Forest apresentou apenas ganho marginal no agregado, que oculta uma redistribuição interna: o balanceamento de pesos elevou o recall de médio risco de 0,63 para 0,70, mas reduziu o de alto risco de 0,82 para 0,74. Comportamento coerente com o critério adotado, que trata as três classes como igualmente importantes.

DEFINIÇÃO DO MODELO FINAL

Esta etapa produziu a configuração adotada como modelo oficial do trabalho: XGBoost ajustado sobre as doze variáveis comportamentais, sem balanceamento de classes. As etapas seguintes tiveram por objetivo validá-lo, interpretá-lo e submetê-lo a alternativas concorrentes.

ANÁLISE

OBJETIVO

Verificar se o desempenho obtido é estável ou se depende da divisão específica entre treino e teste. Uma única partição pode, por acaso, reservar para o teste um conjunto de usuários mais fácil ou mais difícil que a média, produzindo métricas não representativas.

PROCEDIMENTO

Validação cruzada estratificada em dez divisões sobre a base completa. O modelo foi treinado e avaliado dez vezes, cada uma testando em uma partição diferente, permitindo calcular média e desvio padrão de cada métrica. Foram gerados também a matriz de confusão e a curva ROC do modelo treinado na partição 80/20.

RESULTADO — MÉDIAS MACRO EM DEZ DIVISÕES

MÉTRICA	MÉDIA	DESVIO PADRÃO
AUC	0,917	± 0,010
F1-score	0,796	± 0,015
Recall	0,799	± 0,016

RESULTADO — DESEMPENHO POR CLASSE

CLASSE	AUC	F1	RECALL
Baixo risco	0,984 ± 0,006	0,914 ± 0,019	0,959 ± 0,016
Médio risco	0,881 ± 0,020	0,655 ± 0,034	0,609 ± 0,060
Alto risco	0,886 ± 0,013	0,819 ± 0,011	0,828 ± 0,027

cv10_xgb_behavioral_folds.csv

cv10_xgb_behavioral_summary.csv

matriz_confusao_xgb_tunado.png

curva_roc_xgb_tunado.png

ANÁLISE

Os desvios padrão baixos confirmam a estabilidade do modelo entre partições. O AUC macro de 0,917 obtido na validação cruzada é praticamente idêntico ao 0,915 medido no conjunto de teste, indicando que o resultado não decorre de uma divisão

favorável. A classe de médio risco permanece a mais instável, com desvio de 0,060 no recall.

A matriz de confusão revelou o padrão de erro do sistema: acerto de 96,6% na classe de baixo risco, 82,6% na de alto risco, e concentração do erro na classe intermediária, em que 37,7% dos casos reais de médio risco são classificados como alto risco. O modelo erra predominantemente no sentido de superestimar a severidade.

Balanceamento de classes

TESTADO E NÃO ADOTADO

OBJETIVO

Avaliar se técnicas de balanceamento reduziram a proporção de casos de médio risco classificados como alto risco. A classe de alto risco tem o dobro de exemplos das demais, o que cria incentivo estatístico para o modelo recorrer a ela diante de casos ambíguos.

PROCEDIMENTO

Três cenários comparados sob condições idênticas: o modelo oficial sem balanceamento; ponderação de amostras inversamente proporcional à frequência de cada classe; e geração de exemplos sintéticos da classe minoritária pela técnica SMOTE, aplicada exclusivamente ao conjunto de treinamento para não contaminar a avaliação.

RESULTADO — ERRO DE MÉDIO CLASSIFICADO COMO ALTO

CENÁRIO	CASOS	PROPORÇÃO
Sem balanceamento (oficial)	77 / 204	37,7%
Ponderação de amostras	49 / 204	24,0%
SMOTE	51 / 204	25,0%

RESULTADO — EFEITO SOBRE AS CLASSES

CLASSE / MÉTRICA	SEM BALANC.	PONDERAÇÃO	SMOTE
Médio — recall	0,618	0,755	0,735
Médio — F1	0,667	0,675	0,676
Alto — recall	0,826	0,691	0,713

CLASSE / MÉTRICA	SEM BALANC.	PONDERAÇÃO	SMOTE
Alto — F1	0,818	0,763	0,774
Baixo — recall	0,966	0,971	0,971

EXPERIMENTO_matrizes_confusao_balanceamento.png

EXPERIMENTO_metricas_balanceamento.png

EXPERIMENTO_comparativo_balanceamento_por_classe.csv

ANÁLISE E DECISÃO

Ambas as técnicas reduziram em cerca de treze pontos percentuais o erro de médio classificado como alto, mas ao custo de reduzir entre onze e treze pontos o recall da classe de alto risco. O erro não foi eliminado, foi transferido — e transferido justamente para a classe em que tem maior custo prático.

Um detalhe reforça essa leitura: o F1-score da classe de médio risco praticamente não se alterou, passando de 0,667 para 0,675. O recall subiu porque o modelo passou a atribuir a classe intermediária com mais frequência, mas a precisão caiu proporcionalmente. Não houve aprendizado melhor da classe, apenas deslocamento do limiar de decisão.

Registra-se também que o SMOTE, técnica mais elaborada por gerar dados sintéticos, não superou a simples ponderação de amostras neste conjunto de dados.

FUNDAMENTO DA DECISÃO

Os custos dos dois erros possíveis são assimétricos. Um usuário de médio risco classificado como alto risco recebe uma intervenção mais restritiva do que necessitaria — um transtorno. Um usuário de alto risco classificado como médio risco recebe apenas um limite de depósito quando precisaria de suspensão da conta, e o sistema conclui que a situação está sob controle quando não está. O primeiro erro custa conveniência; o segundo compromete a própria finalidade do sistema. O modelo sem balanceamento foi mantido por errar preferencialmente no sentido menos danoso.

OBJETIVO

Verificar se a combinação das predições do Random Forest e do XGBoost ajustados superaria o desempenho de cada um isoladamente. Modelos que erram em casos distintos podem se corrigir mutuamente quando combinados.

PROCEDIMENTO

Duas formas de combinação foram testadas. Na votação por maioria, cada modelo contribui apenas com sua resposta final. Na média de probabilidades, cada modelo contribui com o grau de confiança atribuído a cada classe, e a decisão resulta da soma dessas confianças.

RESULTADO — MÉDIAS MACRO

MODELO	AUC	F1	RECALL
XGBoost isolado	0,915	0,801	0,803
Ensemble	0,915	0,797	0,805
Random Forest isolado	0,913	0,780	0,796

RESULTADO — RECALL POR CLASSE

CLASSE	RANDOM FOREST	XGBOOST	ENSEMBLE
Baixo risco	0,956	0,966	0,961
Médio risco	0,696	0,618	0,657
Alto risco	0,737	0,826	0,797

EXPERIMENTO_ensemble_metricas.png

EXPERIMENTO_ensemble_matriz_confusao.png

EXPERIMENTO_ensemble_por_classe.csv

EXPERIMENTO_ensemble_resumo_macro.csv

ANÁLISE E DECISÃO

A combinação não superou o XGBoost isolado, ficando empatada ou ligeiramente abaixo em quase todas as métricas. Os dois modelos concordaram em 92,3% das predições — ambos são baseados em árvores e aprendem padrões semelhantes, restando pouco espaço para correção mútua. Nos 7,7% de divergência, a média de

probabilidades acabou diluindo a vantagem do XGBoost na classe de alto risco, cujo recall caiu de 0,826 para 0,797.

Um achado técnico secundário merece registro: com apenas dois modelos, a votação por maioria é matematicamente degenerada. Só existe maioria quando ambos concordam, e nos empates é necessário recorrer às probabilidades de qualquer forma. As previsões produzidas pelas duas formas de combinação foram idênticas neste conjunto de teste. A média de probabilidades é, portanto, estrategicamente superior, por produzir probabilidades bem definidas e permitir o cálculo de AUC.

O ensemble foi descartado por não oferecer ganho que justificasse dobrar o custo computacional e a complexidade de manutenção da arquitetura proposta.

Interpretabilidade do modelo final

ANÁLISE

OBJETIVO

Determinar quais das doze variáveis comportamentais efetivamente sustentam as decisões do modelo oficial e como cada uma se relaciona com cada classe de risco.

PROCEDIMENTO

Análise SHAP sobre o modelo final, com geração do ranking de importância e dos gráficos de distribuição de impacto individual para as três classes de risco separadamente.

RESULTADO — RANKING DE IMPORTÂNCIA

POSIÇÃO	VARIÁVEL	SHAP MÉDIO
1º	total_apostado	0,74
2º	numero_total_apostas	0,23
3º	variedade_produtos	0,18
4º	desvio_padrao_apostado	0,13
5º	total_perdas	0,12

- shap_final_importancia_geral.png
- shap_final_beeswarm_alto_risco.png
- shap_final_beeswarm_medio_risco.png

shap_final_beeswarm_baixo_risco.png

shap_final_ranking_completo.csv

COMPORTAMENTO DAS TRÊS CLASSES

Alto risco. Relação monotônica e nítida. Valores elevados de total apostado, número de apostas e total de perdas empurram consistentemente a predição na direção da classe; valores baixos empurram no sentido oposto. A tendência de crescimento do valor apostado também apresenta leitura direta.

Baixo risco. Direção clara no total apostado, mas com dispersão maior nas variáveis intermediárias. Ser classificado como baixo risco depende da combinação simultânea de vários fatores moderados, não de um indicador dominante isolado.

Médio risco. Relação não monotônica, em formato de faixa. Tanto valores muito baixos quanto muito altos de total apostado empurram a predição para longe da classe; apenas a região intermediária empurra a favor.

ACHADO QUE FECHA A ANÁLISE

O comportamento de faixa da classe de médio risco explica retroativamente o resultado da etapa 04. A regressão logística obteve recall de apenas 0,363 nessa classe porque um modelo linear estabelece relações constantes do tipo "mais de X aumenta a probabilidade de Y" — sendo estruturalmente incapaz de representar "valores intermediários indicam a classe, extremos não". Não foi limitação de configuração, foi limitação do algoritmo diante da natureza do problema. Isso justifica tecnicamente a superioridade dos algoritmos baseados em árvores, que particionam o espaço em faixas e representam esse padrão naturalmente.

MODELO FINAL

Ao longo das quatorze etapas, quatro algoritmos foram comparados e três alternativas concorrentes foram testadas contra o modelo selecionado. A configuração adotada é a que sobreviveu a esse percurso.

CONFIGURAÇÃO ADOTADA

XGBoost ajustado — 12 variáveis comportamentais

n_estimators 279

max_depth 3

learning_rate 0,021

subsample 0,764

colsample_bytree 0,720

min_child_weight 2

gamma 0,114

AUC MACRO

0,917 ± 0,010

F1 MACRO

0,796 ± 0,015

RECALL MACRO

0,799 ± 0,016

RECALL ALTO RISCO

0,828 ± 0,027

VALIDAÇÃO

10 divisões

BALANCEAMENTO

Não aplicado

01 Desempenho na classe de alto risco comparável à literatura

Os estudos revisados no trabalho predizem eventos observados — autoexclusão, marcação por programas de jogo responsável, pontuação clínica — e reportaram AUC entre 0,60 e 0,79. A comparação pertinente é com a classe de alto risco, a única deste modelo definida por evento real: nela o AUC foi de 0,884 no conjunto de teste. O valor macro de 0,917 não é diretamente comparável, porque duas das três classes resultam de um corte estatístico definido no próprio trabalho, e a de baixo risco é parcialmente reconstruível a partir das variáveis de entrada. Diferenças de base, população e período limitam ainda a comparação.

02 Estabilidade comprovada

A validação cruzada em dez divisões produziu desvios padrão baixos em todas as métricas — 0,010 no AUC macro. O resultado de 0,915 medido no conjunto de teste e o de 0,917 obtido na validação cruzada são praticamente idênticos,

afastando a hipótese de que o desempenho decorra de uma partição favorável dos dados.

03 Ausência de viés geográfico

A análise de interpretabilidade da etapa 07 revelou que a inclusão de variáveis demográficas fazia o modelo aprender padrões de fiscalização regulatória em vez de comportamento de jogo. A remoção dessas variáveis custou entre dois e quatro pontos percentuais, mas garante que a classificação se sustente exclusivamente sobre como o usuário joga.

04 Equilíbrio entre as três classes

O ajuste da etapa 06, focado apenas na classe de alto risco, produziu no Random Forest um modelo que praticamente eliminou a capacidade de reconhecer a classe intermediária. O ajuste pelo recall médio das três classes evitou esse desequilíbrio, mantendo o modelo funcional em todos os níveis de intervenção previstos na proposta.

05 Padrão de erro alinhado ao contexto de aplicação

Quando erra, o modelo superestima a severidade: 37,7% dos casos de médio risco são classificados como alto risco, enquanto o erro inverso é raro. Em jogo responsável, aplicar uma intervenção mais restritiva que a necessária causa transtorno; aplicar uma menos restritiva compromete a proteção. O modelo erra no sentido menos danoso.

06 Superioridade confirmada contra alternativas

Três abordagens foram testadas para superá-lo. O balanceamento de classes transferiu erro do médio para o alto risco sem eliminá-

lo. A geração de dados sintéticos não superou a ponderação simples. A combinação com o Random Forest não agregou desempenho, por concordância excessiva entre os modelos. Nenhuma se mostrou preferível.

07 Decisões interpretáveis

A análise SHAP demonstrou que o modelo se apoia em variáveis comportamentais coerentes com os indicadores apontados pela literatura, com relações que admitem leitura direta. Essa transparência é requisito para um sistema cujas decisões acionam intervenções automatizadas sobre usuários.

LIMITAÇÃO RECONHECIDA

A classe de médio risco apresenta o desempenho mais fraco do modelo, com recall de 0,609 e o maior desvio entre divisões. A causa é metodológica e não decorre do algoritmo: enquanto a classe de alto risco corresponde a um evento concreto — a marcação pelo programa de jogo responsável da operadora —, a fronteira entre baixo e médio risco resulta de um corte estatístico em uma distribuição contínua. Usuários imediatamente acima e abaixo do limiar são comportamentalmente quase indistinguíveis. A análise SHAP confirmou essa natureza ao revelar a relação não monotônica dessa classe com as variáveis preditoras.


Gráficos do modelo final

Diagnósticos e análises de interpretabilidade do XGBoost ajustado, produzidos nas etapas 10, 11 e 14.

| matriz_confusao_xgb_tunado.png

Matriz de confusão


Distribuição dos acertos e erros do modelo final por classe. Evidencia o acerto de 96,6% na classe de baixo risco, 82,6% na de alto risco, e a concentração do erro nos 37,7% de casos de médio risco classificados como alto risco.



curva_roc_xgb_tunado.png

Curva ROC por classe

Capacidade de discriminação do modelo em cada nível de risco: 0,983 para baixo risco, 0,877 para médio risco e 0,884 para alto risco, todas substancialmente acima do desempenho aleatório.



grafico_tuning_behavioral_xgb.png

Efeito do ajuste de hiperparâmetros


Comparação das métricas do XGBoost antes e depois do ajuste pelo recall médio das três classes, demonstrando ganho simultâneo em AUC, F1-score e recall.



shap_final_importancia_geral.png

Importância das variáveis

As doze variáveis comportamentais ordenadas por impacto médio nas predições, com a contribuição decomposta por classe de risco.



shap_final_beeswarm_alto_risco.png

Impacto individual — alto risco

Distribuição do efeito de cada variável sobre a predição de alto risco. O padrão monotônico é nítido: valores elevados empurram consistentemente na direção da classe.

 shap_final_beeswarm_medio_risco.png

Impacto individual — médio risco

Distribuição do efeito de cada variável sobre a predição de médio risco. Revela a relação em formato de faixa que explica a dificuldade dessa classe e o desempenho inferior da regressão logística.

 shap_final_beeswarm_baixo_risco.png

Impacto individual — baixo risco

Distribuição do efeito de cada variável sobre a predição de baixo risco, com direção clara no total apostado e maior dispersão nas variáveis intermediárias.

Registro de experimentos — modelo de classificação de risco

14 etapas · 4 algoritmos · 4.113 usuários